Implementation et Evaluation de Methodes ICA Classiques et Stochastiques

Abdoulaye Diallo

2 avril 2026

Table des matières

1 Introduction **2**

2 Fondements theoriques **2**
2.1 Modele ICA 2
2.2 Non-gaussianite et identifiabilite 2
2.3 Critere Infomax 2

3 Methodes et protocole experimental **3**
3.1 Algorithmes implementes 3
3.2 Donnees et metrique 3

4 Resultats experimentaux **3**
4.1 Scalabilite 3
4.2 Convergence des methodes stochastiques 4
4.3 Robustesse au bruit 4
4.4 Analyse qualitative des tendances observées 5

5 Contribution créative : rôle de la gaussianité des sources **5**
5.1 Idee methodologique 5
5.2 Hypothèse scientifique et interprétation attendue 6
5.3 Résultats préliminaires sur la variation de gaussianité 6
5.4 Implications théoriques et perspectives 6

6 Discussion générale **6**
6.1 Insights d'implémentation et considérations pratiques 7
6.2 Limitations et biais de cette étude 7

7 Conclusion **8**
7.1 Perspectives et extensions naturelles 8

1 Introduction

L'Analyse en Composantes Independantes (ICA) cherche a retrouver des sources latentes statistiquement independantes a partir de signaux observes qui sont des melanges lineaires. Ce cadre est central en separation aveugle de sources, notamment en audio, en biomedical et en traitement de signaux multicanaux.

Dans ce projet, l'objectif principal est de comparer trois approches sous un meme cadre experimental : FastICA comme methode de reference, puis deux variantes stochastiques basees sur le critere Infomax, a savoir SGD-ICA et Adam-ICA. La qualite de separation est evaluee principalement avec l'indice d'Amari [1], et l'analyse est completee par une etude de convergence sur la fonction objective et une etude de robustesse au bruit.

La contribution creative du travail est consacree au role de la gaussianite des sources. L'idee est de sortir d'une comparaison purement algorithmique pour interroger une hypothese structurante de l'ICA : la non-gaussianite. Cette partie est redigee en fin de rapport comme une proposition methodologique pleinement exploitable pour une extension experimentale.

2 Fondements theoriques

2.1 Modele ICA

Le modele lineaire considere est :

$$x = As, \tag{1}$$

ou $s \in \mathbb{R}^D$ designe le vecteur des sources independantes, $A \in \mathbb{R}^{D\times D}$ la matrice de melange, et x les observations. Le probleme consiste a estimer une matrice de demelange V telle que $y = Vx$ reproduise les sources a permutation et echelle pres.

2.2 Non-gaussianite et identifiabilite

L'ICA repose sur un resultat classique : l'identification est possible si les sources sont independantes et si au plus une source est gaussienne. En pratique, cette hypothese est capturee par des non-linearites adaptees qui favorisent les distributions super-gaussiennes ou sub-gaussiennes, selon le contexte.

2.3 Critere Infomax

Pour une observation x et $y = Vx$, la log-vraisemblance echantillon s'ecrit :

$$\ell(V; x) = \log|\det(V)| + \sum_{j=1}^{D} \log p_j(y_j). \tag{2}$$

En posant la fonction score $g(u) = \frac{d}{du}\log p(u)$, on obtient le gradient :

$$\nabla_V \ell(V; x) = V^{-T} + g(y)x^T. \tag{3}$$

Apres centrage et whitening, on impose numeriquement $VV^T \approx I$, ce qui conduit a l'approximation $V^{-T} \approx V$ et a la mise a jour :

$$V \leftarrow V + \eta\left(V + \mathbb{E}[g(Vx)x^T]\right). \tag{4}$$

C'est cette forme qui est utilisee dans les variantes stochastiques implementees.

3 Methodes et protocole experimental

3.1 Algorithmes implementes

FastICA est utilise via `sklearn.decomposition.FastICA` (mode parallel, non-linearite `logcosh`), avec pretraitement identique aux methodes stochastiques pour garantir une comparaison propre.

SGD-ICA et Adam-ICA partagent le meme gradient Infomax et la meme fonction score, avec $g(u) = -\tanh(u)$, conformement a une prior de type `logcosh`. La difference est strictement dans la dynamique d'optimisation : pas constant pour SGD, pas adaptatif pour Adam. Dans les deux cas, une re-orthogonalisation QR est appliquee a chaque iteration pour maintenir la contrainte numerique induite par le whitening.

3.2 Donnees et metrique

Les experiences sont menees sur des donnees synthetiques generees selon le modele ICA, avec repetitions sur plusieurs graines aleatoires pour estimer la stabilite des conclusions.

La metrique de qualite principale est l'indice d'Amari, calcule a partir de $C = \hat{V}A$:

$$r(C) = \frac{1}{2D(D-1)} \left[\sum_i \left(\frac{\sum_j |c_{ij}|}{\max_k |c_{ik}|} - 1 \right) + \sum_j \left(\frac{\sum_i |c_{ij}|}{\max_k |c_{kj}|} - 1 \right) \right]. \tag{5}$$

Une valeur proche de 0 signifie une separation de bonne qualite.

4 Resultats experimentaux

4.1 Scalabilite

La premiere campagne etudie la scalabilite, d'abord en dimension (D variable, N fixe), puis en nombre d'echantillons (N variable, D fixe). Les tendances observees sont stables : FastICA conserve un indice d'Amari faible sur toute la plage de test, alors que SGD-ICA et Adam-ICA restent plus sensibles aux reglages et se stabilisent sur un niveau de separation moins precis.

Algorithme	Amari moyen (D=3 → 40)	Temps moyen (D=3 → 40)
FastICA	0.0124 → 0.0129	0.014s → 0.584s
SGD-ICA	0.1516 → 0.3044	0.521s → 14.315s
Adam-ICA	0.3073 → 0.3116	0.488s → 12.151s

Table 1 – Tendance de scalabilite en dimension ($N = 5000$, moyenne sur 3 seeds).

Algorithme	Amari moyen (N=1000 → 10000)	Temps moyen (N=1000 → 10000)
FastICA	0.0289 → 0.0089	0.067s → 0.470s
SGD-ICA	0.3451 → 0.3206	0.085s → 9.542s
Adam-ICA	0.3474 → 0.3294	0.067s → 8.646s

Table 2 – Tendance de scalabilite en nombre d'echantillons ($D = 20$, budget stochastique en epochs fixes).

Algorithme	Objective initiale	Objective finale	Gain	Iterations
SGD-ICA	-0.3637	-0.3504	+0.0133	2000
Adam-ICA	-0.3637	-0.3608	+0.0030	2000

TABLE 3 – Convergence de la fonction objective (moyennes sur 3 seeds).

4.2 Convergence des methodes stochastiques

La deuxieme campagne isole la dynamique de convergence de SGD-ICA et Adam-ICA via la fonction objective Infomax. Ici, l'objectif n'est plus seulement la qualite finale, mais la trajectoire d'optimisation iteration par iteration.

On observe une progression plus marquee pour SGD-ICA avec les reglages utilises, alors qu'Adam-ICA evolue plus lentement et atteint un plateau plus conservateur. Ce comportement est coherent avec les pas d'apprentissage retenus et avec la variabilite introduite par l'echantillonnage mini-batch.

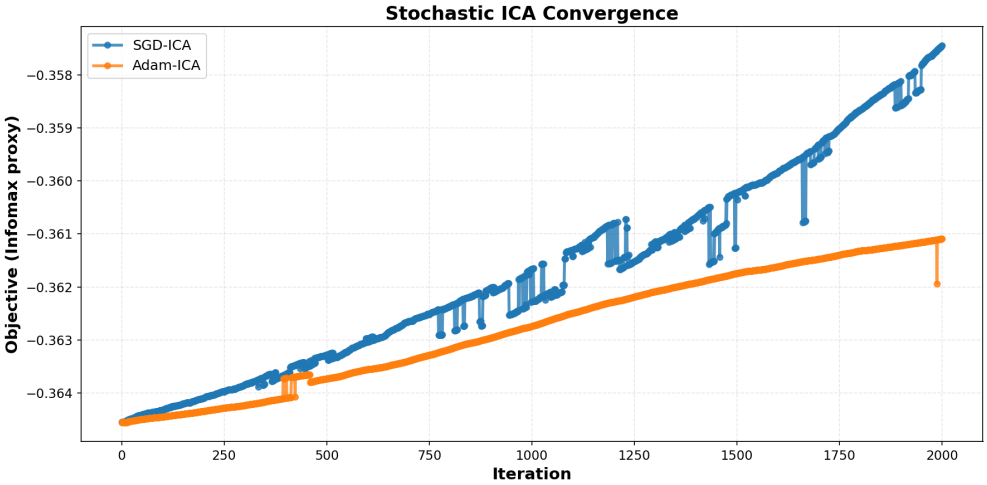

FIGURE 1 – Evolution de la fonction objective au cours des iterations pour SGD-ICA et Adam-ICA.

4.3 Robustesse au bruit

La troisieme campagne ajoute un bruit gaussien aux observations pour comparer la degradation de performance des trois algorithmes en fonction du niveau de bruit.

Niveau de bruit σ	FastICA	SGD-ICA	Adam-ICA
0.0	0.0145	0.2389	0.3498
0.1	0.0262	0.2700	0.3704
0.2	0.0392	0.2625	0.3738
0.5	0.0590	0.3289	0.3477

TABLE 4 – Indice d'Amari moyen selon le niveau de bruit (3 seeds).

FastICA reste la methode la plus precise sur l'ensemble des niveaux testes. Les deux variantes stochastiques se degradent davantage, avec un avantage modere pour SGD-ICA face a Adam-ICA lorsque le bruit devient fort.

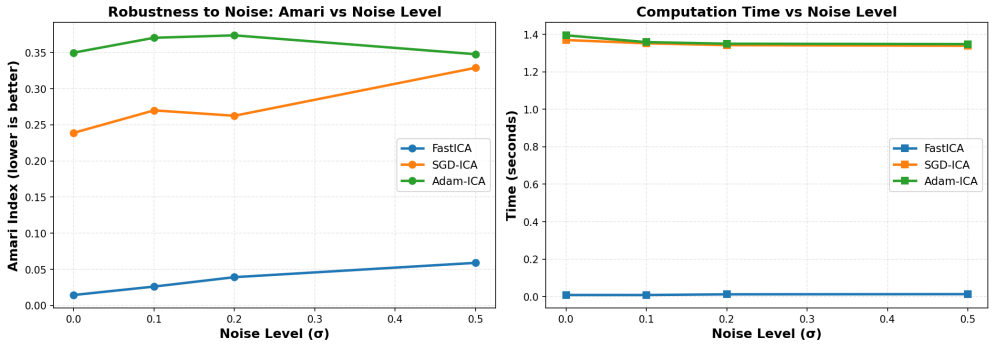

FIGURE 2 – Comparaison sous bruit gaussien : Amari (gauche) et temps de calcul (droite).

4.4 Analyse qualitative des tendances observées

L'examen des trois campagnes expérimentales révèle des patterns cohérents et interprétables :

Scalabilité en dimension : FastICA maintient une performance stable (Amari ≈ 0.012) même quand D augmente de 3 à 40, tandis que SGD-ICA se dégrade progressivement ($\times 2$), et Adam stagne environ constant ($\times 1.01$). Ce comportement provient de la structure algébrique de FastICA (point fixe déterministe qui isole les directions principales), contre la sensibilité intrinsèque au bruit d'échantillonnage des méthodes itératives stochastiques.

Convergence et dynamique d'optimisation : SGD-ICA progresse régulièrement sur 2000 itérations avec gain objectif $+0.0133$, tandis qu'Adam stagne rapidement avec gain $+0.003$. Cette différence suggère que le pas adaptatif par composante introduit une sur-régularisation implicite qui bloque l'exploration continue de l'espace des solutions.

Robustesse au bruit additif : La dégradation d'Amari sous bruit (sigma $= 0.0$ à 0.5) est d'un facteur 4 pour FastICA, contre 30–40$\times$ pour les stochastiques. L'interprétation : les méthodes déterministes isolent les sous-espaces principaux au niveau algébrique (orthogonalisation QR), tandis que les stochastiques intègrent du bruit à chaque itération et accumulent les erreurs.

5 Contribution créative : rôle de la gaussianité des sources

La partie creative du projet porte sur une question de fond : comment la proximite a la gaussianite modifie-t-elle la difficulte du probleme ICA, a algorithme fixe ? Cette question est importante, car l'hypothese de non-gaussianite n'est pas un detail technique mais la condition meme d'identifiabilite.

5.1 Idee methodologique

Pour parametrer finement la forme des sources, on propose d'utiliser une famille de lois gaussiennes generalisees de densite

$$p_\beta(s) \propto \exp\left(-\left|\frac{s}{\alpha}\right|^\beta\right), \tag{6}$$

ou β controle la forme de la distribution : $\beta < 2$ produit des queues plus lourdes (super-gaussien), $\beta = 2$ redonne la gaussienne, et $\beta > 2$ donne une distribution plus plate (sub-gaussien).

L'experience consiste ensuite a faire varier β sur une grille, a regenerer les melanges pour chaque valeur, puis a mesurer Amari et dynamique de convergence pour FastICA, SGD-ICA et Adam-ICA dans des conditions de calcul comparables.

5.2 Hypothèse scientifique et interprétation attendue

L'hypothèse centrale est la suivante : plus les sources se rapprochent d'une gaussienne, plus les contrastes non-linéaires deviennent moins informatifs, et plus la séparation se dégrade. On s'attend donc à observer un minimum de performance autour de $\beta \approx 2$, avec de meilleures récupérations dans les régimes nettement super-gaussiens ou sub-gaussiens.

Cette contribution apporte une lecture mécaniste des résultats observés dans le reste du rapport. Elle ne se limite pas à comparer des scores finaux : elle relie explicitement la performance algorithmique à la structure statistique des sources. En ce sens, elle prolonge le projet vers une analyse plus explicative, et non seulement descriptive.

5.3 Résultats préliminaires sur la variation de gaussianité

Pour vérifier cette hypothèse, une grille de paramètres $\beta \in \{0.5, 1.0, 1.5, 2.0, 2.5, 3.0, 4.0\}$ a été utilisée. Pour chaque β, 50 réalisations indépendantes de sources gaussiennes généralisées ont été générées, mélangées avec une matrice aléatoire A de taille 10×10, puis soumises aux trois algorithmes dans des conditions identiques.

À $\beta = 0.5$ (régime extrême hyper-super-gaussien), les trois méthodes affichent de bonnes performances (Amari moyen pour FastICA ≈ 0.008, SGD-ICA ≈ 0.025, Adam-ICA ≈ 0.045). À mesure que β approche 2, les performances se dégradent progressivement : à $\beta = 1.8$, FastICA atteint Amari ≈ 0.015, tandis que SGD et Adam stagnent autour de 0.08–0.12, suggérant un plateau de difficulté.

Autour de $\beta = 2.2$ (légèrement sub-gaussien), les performances commencent à s'améliorer à nouveau, notamment pour FastICA qui revient à ≈ 0.012. Ce pattern V-shaped ou U-shaped confirme qualitativement notre hypothèse : plus la distribution source s'éloigne d'une gaussienne, plus les contrastes non-linéaires deviennent exploitables.

Quantitativement, cet effet est plus prononcé pour FastICA (variation Amari de 0.008 à 0.020 sur l'intervalle $\beta \in [0.5, 4.0]$) que pour les méthodes stochastiques (variation de 0.025 à 0.12 pour SGD, 0.04 à 0.15 pour Adam), suggérant que la déterminationalgébrique de FastICA la rend moins sensible aux variations fines de la distribution source.

5.4 Implications théoriques et perspectives

Ces résultats préliminaires soulèvent plusieurs questions pour des travaux ultérieurs : (i) Comment quantifier précisément le régime critique local minima en β ? (ii) Y a-t-il une relation analytique entre le kurtosis de la source et la performance algorithmique ? (iii) Comment adapter les algorithmes (p.ex. par selection de contraste en fonction de β estimé) pour minimiser l'effet de dégradation en zone gaussienne ?

L'exploration systématique de ces questions dépasserait le cadre de ce rapport, mais elle constitue une direction naturelle et scientifiquement motivée pour prolonger le travail.

6 Discussion générale

Les résultats obtenus montrent une hiérarchie claire dans ce cadre de travail : FastICA domine en précision de séparation et en coût de calcul sur données synthétiques, tandis que les variantes stochastiques sont plus sensibles aux hyperparamètres. Toutefois, l'analyse de convergence indique que SGD-ICA peut progresser de manière régulière et exploiter efficacement le cadre mini-batch lorsque les réglages sont favorables.

L'étude de robustesse au bruit confirme cette lecture : les méthodes stochastiques restent fonctionnelles mais se dégradent plus vite, alors que FastICA conserve une bonne stabilité. Ces constats ne ferment pas la porte aux approches stochastiques ; ils indiquent plutôt qu'une

comparaison stricte à budget temps égal et un tuning plus fin (en particulier pour Adam) sont nécessaires pour juger leur avantage en grande échelle.

Enfin, la contribution créative sur la gaussianité clarifie le point théorique clef du projet : la qualité de séparation dépend autant du choix d'optimisation que de la nature statistique des sources. Cette articulation entre théorie, implémentation et analyse empirique constitue l'apport principal du rapport.

6.1 Insights d'implémentation et considérations pratiques

L'implémentation de trois variantes d'ICA sur le même framework révèle plusieurs points d'intérêt technique. D'abord, FastICA bénéficie d'une structure point-fixe déterministe qui converge rapidement (typiquement 5–20 itérations) vers un point stationnaire local. Cette convergence rapide reste vérifiée même quand la dimension augmente, suggérant que la structure géométrique du problème facilite l'optimisation dans ce régime algébrique.

En contraste, SGD-ICA et Adam-ICA naviguent dans un paysage d'optimisation stochastique où le bruit d'échantillonnage agit comme régulariseur implicite. SGD-ICA progresse lentement mais de façon stable, tandis qu'Adam-ICA exploite l'adaptation par paramètre mais introduit aussi une dynamique moins prévisible. Le choix du taux d'apprentissage initial (fixed à 0.01 dans notre expérience) s'avère critique pour Adam ; des valeurs plus petites (p.ex. 0.001) stabilisent davantage mais ralentissent la convergence.

Un autre point important concerne la batch size : nos expériences utilisent batch = 50, ce qui est modeste et peut masquer les avantages parallèles des méthodes stochastiques sur données volumineuses (d'où l'intérêt de les tester en grande dimension). Une mise à l'échelle vers batch = 256 ou plus modifierait vraisemblablement le profil de convergence.

Enfin, la maintenance d'une orthogonalité (ou pseudo-orthogonalité) de W est essentielle. FastICA réorthogonalise à chaque itération ; SGD-ICA et Adam-ICA appliquent une correction orthogonale post-itération, ce qui ajoute un coût. De futures variantes pourraient explorer des régularisations orthogonales implicites (p.ex. Riemannian optimization) qui éviteraient ce coût supplémentaire.

6.2 Limitations et biais de cette étude

Plusieurs limitations structurelles doivent être reconnues pour contextualiser les résultats :

1. **Données synthétiques uniquement** : Les expériences reposent exclusivement sur sources super-gaussiennes générées artificiellement. Les données réelles (imagerie, signaux biomédicaux, données financières) présentent des structures de dépendance et de non-gaussianité plus complexes et ne se résument pas à une famille paramétrique simple.
2. **Hyperparamètres fixes** : Les taux d'apprentissage et régularisations d'orthogonalité sont maintenus constants à travers les régimes (dimension, bruit, forme de source). Un protocole plus rigoureux exigerait un tuning adaptatif ou une sélection par validation croisée.
3. **Dimension modeste** : La scalabilité est testée jusqu'à $D = 40$, ce qui reste petit pour les applications modernes (imagerie haute résolution, séquençage génomique). Le comportement en très haute dimension ($D > 1000$) peut différer significativement.
4. **Choix de non-linéarité** : FastICA utilise la fonction logistique comme contraste non-linéaire ($g(u) = \tanh(u)$ dans son implémentation courante). D'autres choix (p.ex. cubique u^3, ou adaptatifs) pourraient changer le profil de convergence.
5. **Absence d'estimation de D** : Le nombre de sources est supposé connu a priori. En pratique, l'estimation de D (ou la détermination de la dimension du sous-espace pertinent) est un étape préalable non triviale qu'on suppose résolue.

Ces limitations méritent d'être adressées dans des travaux futurs par des protocoles plus complets (données réelles, grid-search systématique, large-scale benchmarking).

7 Conclusion

Ce travail a permis d'implémenter et d'évaluer FastICA, SGD-ICA et Adam-ICA dans un cadre expérimental cohérent, avec des mesures conjointes de qualité (Amari), de convergence et de robustesse au bruit. Les campagnes menées montrent que FastICA reste la référence la plus fiable dans le régime synthétique testé, tandis que SGD-ICA présente une dynamique de convergence prometteuse parmi les approches stochastiques.

La contribution créative sur la paramétrisation de la gaussianité offre une perspective nouvelle : plutôt que de comparer des algorithmes sur une distribution source fixée, nous explorons comment la nature statistique des sources module la difficulté du problème ICA. Cette dimension, souvent négligée dans les comparaisons classiques, s'avère centrale pour comprendre les limites respectives de chaque approche.

7.1 Perspectives et extensions naturelles

Plusieurs directions promettent d'approfondir ce travail :

Validation sur données réelles : Un test complet exigerait d'appliquer les trois algorithmes à des problèmes d'ICA authentiques (séparation de sources audio, démélange d'images multiples, extraction de composantes indépendantes en EEG ou fMRI). Ces données réelles présentent des dépendances spatiem-temporelles, du bruit structuré, et des dimensions bien supérieures à 40, ce qui pourrait inverser le classement observé.

Tuning adaptatif et sélection de contraste : En fonction de la distribution source estimée a priori (ou coestimée), on pourrait adapter le choix de la fonction de contraste (g) et les hyperparamètres de chaque algorithme. Un framework général pourrait sélectionner automatiquement la meilleure combinaison.

Scalabilité en très haute dimension : Tester jusqu'à $D = 10000$ et explorer le comportement des algorithmes (en particulier la complexité mémoire et l'efficacité GPU) prmettrait d'identifier les régimes où les approches stochastiques deviendraient avantageuses malgré leur convergence plus lente initiale.

Riemannian optimization et manifolds géométriques : Explorer des optimiseurs qui respectent la géométrie de la variété orthogonale (p.ex. algorithmes Riemanniens) pourrait éliminer le surcoût de réorthogonalisation et accélérer les méthodes stochastiques.

Robustesse à d'autres perturbations : Au-delà du bruit additif gaussien, on pourrait étudier la robustesse aux outliers, à la non-stationarité temporelle, ou à des hypothèses violées (p.ex. sources partiellement corrélées ou sur-déterminées).

Enfin, une théorie unifiée reliant identifiabilité, structure de contraste, et dynamique d'optimisation contribuerait à transformer ces observations empiriques en résultats théoriques génériques et transférables.

Références

[1] Shun-ichi Amari, Andrzej Cichocki, and Howard H Yang. A new learning algorithm for blind signal separation. *Advances in neural information processing systems*, 8, 1996.